

Multilingvistický slovník

Autor: Viktor Modroczký

Predmet: Vyhľadávanie informácií

Téma projektu je **Vytvorenie multilingvistického slovníka z wikipédie slovenčina vs. iné jazyky (aspoň 2), vytvoriť spoločný slovník spájajúci jazyky s možnosťou vyhľadávania.**

Projekt je riešený v jazyku **Java 17** s build nástrojom **Maven**.

Ide o nástroj pre tzv. Cross-language Information Retrieval (CLIR). CLIR je oblasť vyhľadávania informácií, ktorá sa zaoberá vyhľadávaním informácií v iných jazykoch ako jazyk dopytu používateľa [1]. Riešenie sa môže považovať za implementáciu CLIR pomocou Dictionary-Based Query Translation (DBQT), ktoré spočíva v tom, že sú paralelné texty dopredu vydolované (napr. z Wikipédie) a ich mapovanie je uložené v slovníku [2]. Preklady sa vyhľadávajú tak, že sa v zdrojovom jazyku vyhľadajú dopytu vyhovujúce dokumenty a zároveň ich preklady do ďalších dvoch jazykov.

Rámce a knižnice

Vo verzii 2

Apache Commons na spracúvanie CSV súborov.

Apache Lucene na indexovanie.

Apache Spark na distribuované spracovanie.

Gson na spracúvanie JSON súborov.

Dotenv-Java na otváranie **.env** súboru.

MySQL Connector Java na pripojenie k MySQL databáze.

Vo verzii 1

Apache Commons na spracúvanie CSV súborov a reťazcov.

Gson na spracúvanie JSON súborov pre vlastný index. **Dotenv-Java** na otváranie **.env** súboru.

MySQL Connector Java na pripojenie k MySQL databáze.

Dataset

[Slovenská Wikipedia](#)

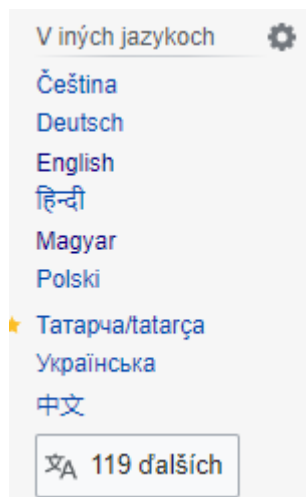
[Česká Wikipedia](#)

[Maďarská Wikipedia](#)

Zámer

Zámerom projektu je vytvorenie viacjazyčného slovníka z dát z Wikipédie, v ktorom bude používateľovi umožnené vyhľadávať.

Na každej Wikipedia stránke je v ľavom paneli sekcia *V iných jazykoch* (obrázok nižšie), ktorá obsahuje prepojenia na články v iných jazykoch. Na tieto prepojenia sa využívajú tzv. Interwiki Links, presnejšie Interlanguage Links (medzijazyčné odkazy).

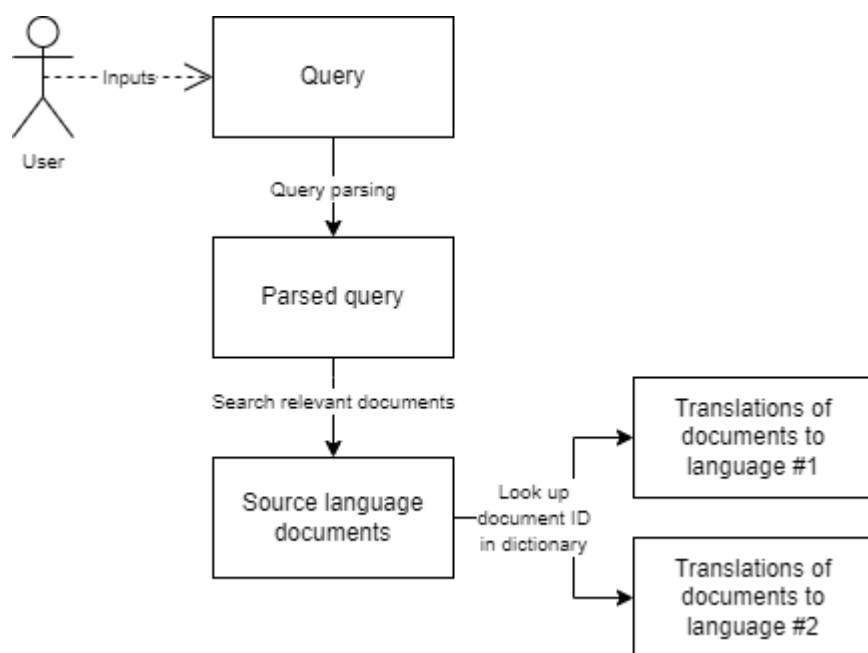


Medzijazyčné odkazy sú uchovávané v relačnej databáze v tabuľke *langlinks* (bude sa používať tabuľka pre slovenskú Wikipédiu). Tabuľka obsahuje 3 stĺpce, a to *ll_from*, *ll_lang* a *ll_title*. Stĺpec *ll_from* je *page_id* odkazujúceho slovenského článku, *ll_lang* je kód jazyka cieľového článku a *ll_title* je názov cieľového článku v jazyku *ll_lang*.

Verzia 2

Kód pre druhú verziu s Apache Lucene indexom a vyhľadávaním a s distribuovaným spracovaním pomocou Apache Spark sa nachádza v release [2.0](#).

Schéma:



V druhej verzii je index vytvorený použitím Apache Lucene. Dáta, ktoré sa indexovali boli distribuovane predspracované pomocou Apache Spark.

Použitie správnych verzií Apache Spark je dôležité pre správne fungovanie distribuovaného spracovania. Boli použité verzie:

[Apache Spark 3.3.1 pre-built for Hadoop](#)

[Apache Hadoop 3.3.1 Windows Bin](#)

Po stiahnutí binárnych súborov Apache Spark a Apache Hadoop je potrebné nastaviť premenné prostredia nasledovne:

```
SPARK_HOME=absolute\path\to\spark-3.3.1-bin-hadoop3
HADOOP_HOME=absolute\path\to\hadoop-3.3.1
```

K premennej **PATH** treba potom pridať:

```
%SPARK_HOME%\bin
%HADOOP_HOME%\bin
```

Dependencies pre Spark **musia** byť nastavené nasledovne, keďže použitá verzia Spark používa Scala 2.12:

```
<dependency>
  <groupId>org.apache.spark</groupId>
  <artifactId>spark-core_2.12</artifactId>
  <version>3.3.1</version>
</dependency>
<dependency>
  <groupId>org.apache.spark</groupId>
  <artifactId>spark-sql_2.12</artifactId>
  <version>3.3.1</version>
  <scope>provided</scope>
</dependency>
```

K Java argumentom treba pridať **--add-exports java.base/sun.nio.ch=ALL-UNNAMED**.

V projekte sa používa **Standalone Mode** pri vykonávaní častí aplikácie distribuovane a je potrebné spustiť master node a worker node-y nasledovne:

Master node sa spúšťa pomocou **spark-class org.apache.spark.deploy.master.Master --host localhost**.

Worker node-y sa spúšťajú pomocou **spark-class org.apache.spark.deploy.worker.Worker spark://localhost:7077 --memory <worker-memory> --cores <worker-threads>**, kde

<worker-memory> treba nahradiť veľkosťou pamäte, ktorú bude môcť daný worker využiť (stačí **1G**, keďže aplikácia WikiTranslator použije no danom worker node iba 1GB, čo je default nastavenie),

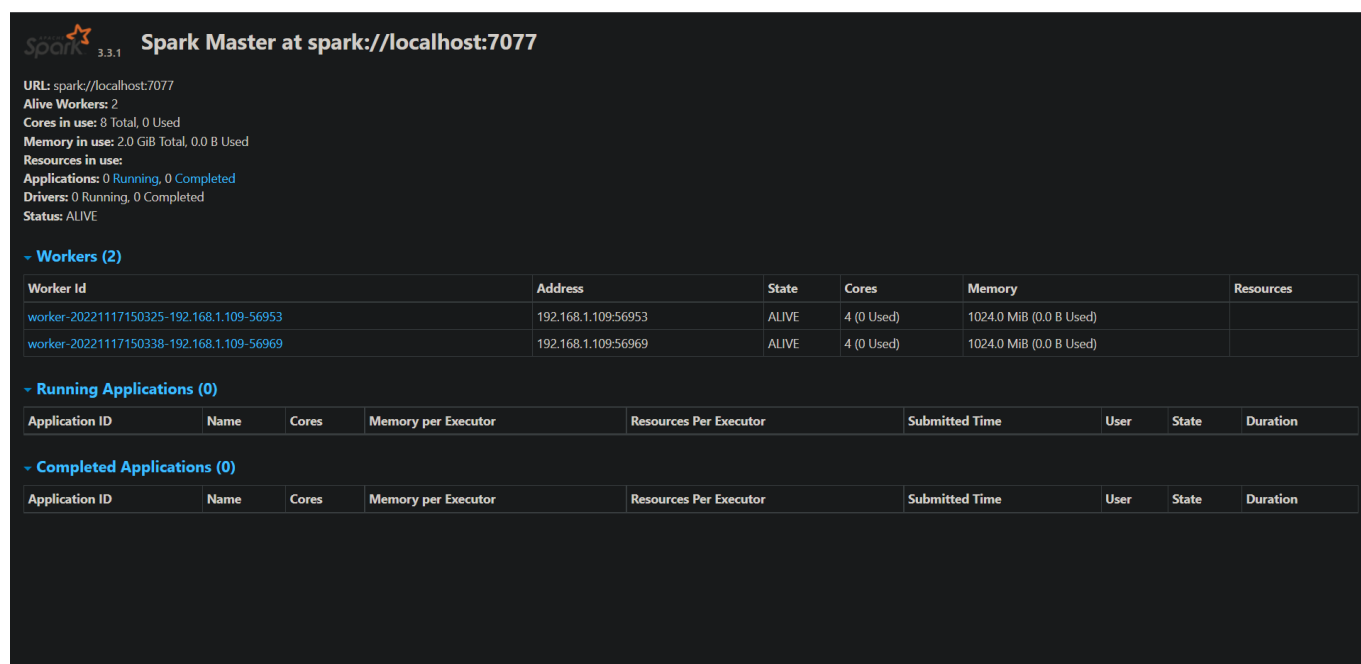
<worker-threads> treba nahradiť počtom vlákien CPU, ktoré môže daný worker používať (napr. ak máme 8 vlákien CPU a chceme spustiť 2 worker node-y, tak pre každý nastavíme hodnotu **4**).

Príklad:

```
spark-class org.apache.spark.deploy.worker.Worker spark://localhost:7077 --cores 4
--memory 1G
```

```
spark-class org.apache.spark.deploy.worker.Worker spark://localhost:7077 --cores 4
--memory 1G
```

Po spustení master a worker node-ov je možné skontrolovať ich stav na <http://localhost:8080/>.



Spark Master at spark://localhost:7077

URL: spark://localhost:7077
 Alive Workers: 2
 Cores in use: 8 Total, 0 Used
 Memory in use: 2.0 GiB Total, 0.0 B Used
 Resources in use:
 Applications: 0 Running, 0 Completed
 Drivers: 0 Running, 0 Completed
 Status: ALIVE

~ Workers (2)

Worker Id	Address	State	Cores	Memory	Resources
worker-20221117150325-192.168.1.109-56953	192.168.1.109:56953	ALIVE	4 (0 Used)	1024.0 MiB (0.0 B Used)	
worker-20221117150338-192.168.1.109-56969	192.168.1.109:56969	ALIVE	4 (0 Used)	1024.0 MiB (0.0 B Used)	

~ Running Applications (0)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
----------------	------	-------	---------------------	------------------------	----------------	------	-------	----------

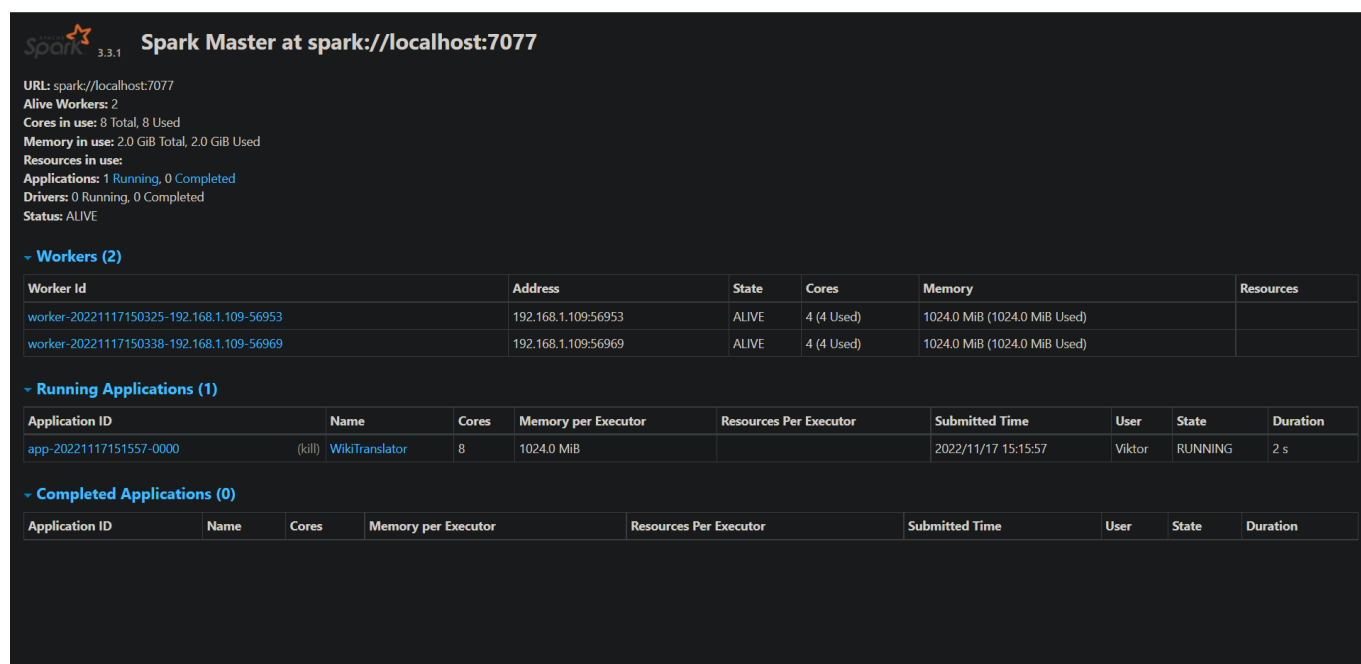
~ Completed Applications (0)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
----------------	------	-------	---------------------	------------------------	----------------	------	-------	----------

Následne je možné spustiť príkazy WikiTranslator-u, ktoré využívajú Apache Spark. Apache Spark (teda bežiaci master node a bežiace worker node-y) používajú iba dva príkazy, a to 3 a 4.

Aplikáciu spustenú na Apache Spark je možné taktiež skontrolovať na <http://localhost:8080/>.

Celkový prehľad:



Spark Master at spark://localhost:7077

URL: spark://localhost:7077
 Alive Workers: 2
 Cores in use: 8 Total, 8 Used
 Memory in use: 2.0 GiB Total, 2.0 GiB Used
 Resources in use:
 Applications: 1 Running, 0 Completed
 Drivers: 0 Running, 0 Completed
 Status: ALIVE

~ Workers (2)

Worker Id	Address	State	Cores	Memory	Resources
worker-20221117150325-192.168.1.109-56953	192.168.1.109:56953	ALIVE	4 (4 Used)	1024.0 MiB (1024.0 MiB Used)	
worker-20221117150338-192.168.1.109-56969	192.168.1.109:56969	ALIVE	4 (4 Used)	1024.0 MiB (1024.0 MiB Used)	


~ Running Applications (1)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
app-20221117151557-0000	(kill) WikiTranslator	8	1024.0 MiB		2022/11/17 15:15:57	Viktor	RUNNING	2 s

~ Completed Applications (0)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
----------------	------	-------	---------------------	------------------------	----------------	------	-------	----------

Detail aplikácie:


Application: WikiTranslator

ID: app-20221117151557-0000
 Name: WikiTranslator
 User: Viktor
 Cores: Unlimited (8 granted)
 Executor Limit: Unlimited (2 granted)
 Executor Memory: 1024.0 MiB
 Executor Resources:
 Submit Date: 2022/11/17 15:15:57
 State: RUNNING
[Application Detail UI](#)

~ Executor Summary (2)

ExecutorID	Worker	Cores	Memory	Resources	State	Logs
1	worker-20221117150325-192.168.1.109-56953	4	1024		RUNNING	stdout stderr
0	worker-20221117150338-192.168.1.109-56969	4	1024		RUNNING	stdout stderr

Zoznam príkazov v aplikácii WikiTranslator je (spúšťajú sa ich poradovým číslom):

1. exit
2. find article ID pairs
3. create sk-cs-hu ID conjunction with Spark
4. create docs with Spark
5. create Lucene index
6. create ID mapping
7. use translation search (type 'exit' for quitting search mode)

Dáta

Zo súborov `skwiki-latest-langlinks.sql.gz`, `cswiki-latest-page.sql.gz` a `huwiki-latest-page.sql.gz` boli SQL súbory importované do lokálnej MySQL databázy, ku ktorej sa aplikácia WikiTranslator pripája použitím prihlasovacích údajov v `.env` súbore v koreňovom adresári projektu. Súbor `.env` musí obsahovať polia:

```
USER=database_owner
PW=password
```

V `langlinks` tabuľke sa hľadajú odkazy na preklady slovenských článkov tak, že z nej vyberieme hodnoty `ll_title`, ak sa `ll_lang` rovná `cs` alebo `hu`. Hodnota `ll_from` je ID slovenského článku. Podľa `ll_title` potom vyberáme z českej alebo maďarskej tabuľky `page` korešpondujúce ID českého alebo maďarského článku.

Na nájdenie `sk - cs` alebo `sk - hu` párov ID slúži v aplikácii WikiTranslator príkaz 2. Následne sa pomocou distribuovaného spracovania so Spark dá spustením programu príkazom 3 vytvoriť prienik `sk - cs - hu`. Súbory `sk-cs.csv` a `sk-hu.csv` pre páry ID a aj Sparkom vygenerovaný prienik (adresár `sk-cs-hu-spark`) sú už vygenerované v repozitári projektu, netreba ich generovať znovu.

Ďalším krokom je spracovanie Wikipedia dumpov pomocou nástroja [WikiExtractor](#), ktorý vyčistí XML dump súbory od WikiText syntaxe a zachová články v [JSON Lines](#) súboroch so schémou:

```
{ "id": "id_value", "revid": "revid_value", "url": "url_value", "title":  
"title_value", "text": "text_value" }\n
```

Nástroj treba spustiť v Docker kontajneri pomocou príkazov:

Build: `docker build --pull --rm -t wikiextractor:latest .`

Run: `docker run --rm -it --mount type=bind,source=%cd%\output,target=/wiki/output
wikiextractor:latest`

Nástroj sa spúšťa pre každý jazyk zvlášť:

- Pre **sk** jazyk v priečinku `dataset/sk-articles`, kde sa musí nachádzať dump `skwiki-latest-pages-articles.xml.bz2`.
- Pre **cs** jazyk v priečinku `dataset/cs-articles`, kde sa musí nachádzať dump `cswiki-latest-pages-articles.xml.bz2`.
- Pre **hu** jazyk v priečinku `dataset/hu-articles`, kde sa musí nachádzať dump `huwiki-latest-pages-articles.xml.bz2`.

Po dokončení čistenia XML súborov je posledným krokom vytvárania dát na indexovanie vytvorenie samotných dokumentov pre slovenské články a ich české a maďarské preklady. Zo spracovaných XML dumpov sa teda podľa zoznamu trojíc ID **sk** - **cs** - **hu** vyberú potrebné články, z ktorých sa vytvoria **sk**, **cs** a **hu** dokumenty. Na to slúži príkaz 4. Dokumenty majú 3 polia, a to **id**, **title** a **text**, ktoré sa pomocou Apache Lucene budú indexovať. Dokumenty sa uložia do priečinkov `documents-sk-spark`, `documents-cs-spark` a `documents-hu-spark`. Tieto priečinky obsahujú [JSON Lines](#) súbory, v ktorých sú dokumenty uložené. Schéma súborov je:

```
{ "id": "id_value", "title": "title_value", "text": "text_value" }\n
```

Spracované dáta pripravené na indexovanie sú dostupné na [Google Drive](#). Priečinky `documents-sk-spark`, `documents-cs-spark` a `documents-hu-spark` musia byť v koreňovom adresári projektu. V každom z nich je 63926 dokumentov.

Indexovanie

Na vytvorenie indexov slúži príkaz 5. Aplikácia dáva na výber vytvorenie indexov pre **sk**, **cs** a **hu** dokumenty zvlášť. Polia **title** a **text** sa indexujú na vyhľadávanie používateľom zadaného textu. Pole **id** sa indexuje iba na to, aby sme vedeli rýchlo vyhľadať preklady k daným dokumentom. Index je dostupný na [Google Drive](#). Adresár `index` musí byť v koreňovom adresári projektu.

Vyhľadávanie

Pred prvým vyhľadávaním treba spustiť príkaz 6, ktorý vytvorí 3 JSON súbory, a to `sk-map.json`, `cs-map.json` a `hu-map.json`. Tieto súbory sú už vygenerované v repozitári projektu, netreba preto príkaz

spúšťať. Tieto súbory slúžia na rýchle zistenie ID prekladov článkov pri vyhľadávaní. Schéma JSON súborov je:

```
{
  "searched_lang_id": [ "translation_1_id", "translation_2_id" ],
}
```

Vyhľadávač sa spúšťa príkazom `7` a jeho syntax je `lang:at:qtext`, kde:

- `lang` je jazyk, v dokumentoch ktorého chceme vyhľadávať. Môže to byť `sk`, `cs` alebo `hu`,
- `at` je pole, v ktorom chceme vyhľadávať. Môže to byť rôzna kombinácia názvov (pole `title` = `T`) a textov (pole `text` = `t`) článkov. Môže to byť `T`, `t`, `T&t`, `t&T`, `T|t` alebo `t|T`. `T`, kde znak `&` znamená 'a zároveň' a znak `|` znamená 'alebo'.
- `qtext` je text, ktorý sa má vyhľadávať v danom jazyku - použité analyzéry textu z Apache Lucene pri indexovaní neodstraňujú diakritiku (`CzechAnalyzer` pre slovenčinu a češtinu a `HungarianAnalyzer` pre maďarčinu), preto funguje vyhľadávanie s diakritikou.

Vyhľadávanie vráti zjednodušený výsledok v konzole (výpisy neobsahujú pole `text`) a kompletný výsledok v súbore `output.json` v koreňovom adresári projektu. Vo výstupe sa nachádza top 10 vyhovujúcich výsledkov.

Schéma výsledného JSON súboru je:

```
{
  "searchResult": [
    {
      "lang1": {
        "id": "id_value",
        "title": "title_value",
        "text": "text_value"
      },
      "lang2": {
        "id": "id_value",
        "title": "title_value",
        "text": "text_value"
      },
      "lang3": {
        "id": "id_value",
        "title": "title_value",
        "text": "text_value"
      }
    },
    {
      "lang1": {
        "id": "id_value",
        "title": "title_value",
        "text": "text_value"
      },
      "lang2": {
        "id": "id_value",
        "title": "title_value",
        "text": "text_value"
      },
      "lang3": {
        "id": "id_value",
        "title": "title_value",
        "text": "text_value"
      }
    }
  ]
}
```

Príklad:

Vstup `sk:T&t:covid test` vráti do konzoly výsledok:

```
ID Language Title
-----
667655 SK Rýchly antigénový test COVID-19
1688511 CS Rychlý antigenní test na covid-19
1773397 HU Covid19-antigén gyorsteszt
-----
667137 SK Rýchly antigénový test
1688600 CS Rychlý antigenní test
1774498 HU Antigén gyorsteszt
-----
645499 SK COVID-19
1564791 CS Covid-19
1683177 HU Covid19
-----
102017 SK Test
242872 CS Testování
11604 HU Test (egyértelműsítő lap)
-----
646838 SK Pandémia ochorenia COVID-19
1559185 CS Pandemie covidu-19
1679312 HU Covid19-pandémia
-----
905 SK Turingov test
4218 CS Turingův test
182823 HU Turing-teszt
-----
444545 SK Kolmogorovov-Smirnovov test
324710 CS Kolmogorovův?Smirnovův test
979361 HU Kolmogorov?Szmirnov-próba
-----
339758 SK Klasická teória testov
913998 CS Klasická testová teorie
493883 HU Klasszikus tesztelmélet
-----
652542 SK Vakcína proti chorobe COVID-19
1651518 CS Vakcína proti covidu-19
1689580 HU Covid19-vakcína
-----
526502 SK Crash Test Dummies
694195 CS Crash Test Dummies
1830033 HU Crash Test Dummies
-----
```

Celý výsledok je v súbore [output.json](#).

Verzia 1

Kód pre prvú verziu s vlastným indexom, vlastným vyhľadávaním a bez distribuovaného spracovania sa nachádza v release [1.0](#).

V tabuľke *langlinks* budeme vyhľadávať preklady článkov podľa kódov jazykov pomocou stĺpca *ll_lang*. Názvy článkov v slovenčine nájdeme pomocou hodnoty zo stĺpca *ll_from*, a to tak, že v tabuľke *page* pre slovenské články nájdeme *page_title* slovenských názvov podľa hodnôt *page_id*, ktoré zodpovedajú hodnotám *ll_from* v tabuľke *langlinks*. Hodnoty *ll_title* sa budú ukladať ako preklady slovenských názvov. Prekladač bude vytvorený vo forme vyhľadávača, ktorý bude vracať výsledky na základe zadanej požiadavky. Napr. sa zadá slovo a jazyk, v ktorom sa má dané slovo vyhľadať, a potom sa vrátia všetky dokumenty (názvy článkov) aj s prekladmi do ostatných 2 jazykov, ktoré obsahujú dané slovo.

Formát dokumentov

Každý dokument má *id* a verziu v slovenčine (*sk*), češtine (*cs*) a maďarčine (*hu*).

```
id,sk,cs,hu
1,Fridrich I. Habsburský,Fridrich I. Habsburský,(III.) Frigyes német király
2,Nulové zariadenie,/dev/null,/dev/null
3,0 (číslo),Nula,0 (szám)
4,1 (číslo),1 (číslo),1 (szám)
5,1 euro,1 euro,1 eurós érme
6,"1,2 - dichlóretán","1,2-dichlorethan","1,2-Diklóretán"
7,"1,4-dioxán","1,4-dioxan","1,4-Dioxán"
8,Linka 1 (parížske metro),1 (linka metra v Paříži),1-es metró (Párizs)
9,Prvý česko-slovenský armádny zbor v ZSSR,1. československý armádní sbor,1.
Csehszlovák Hadtest
10,1. FC Lokomotive Leipzig (1966),1. FC Lokomotive Leipzig (1966),1. FC
Lokomotive Leipzig
```

Ako funguje vyhľadávanie?

Dokumenty sú indexované pomocou vlastného inverzného indexu pre každý jazyk, ktorý má formát:

token: ID[] - každý unikátny token má zoznam článkov, v ktorom sa nachádza.

```
"stred": [
  "57622",
  "7259",
  "10883"
],
"poseidon": [
  "47671",
  "46947"
],
"palec": [
  "15616"
],
"hebrejcina": [
  "28625",
  "15510"
]
```

Indexy sú pri vytvorení inštancie triedy `SearchEngine` načítané z JSON súborov do `HashMap`y, aby bola efektivita vyhľadávania článkov so zhodou $O(1)$. Pri vyhľadávaní sa vráti zoznam dokumentov, ktoré zodpovedajú dopytu.

Syntax vyhľadávača

`lang:qtext`, kde:

- `lang` môže byť `sk`, `cs` alebo `hu`,
- `qtext` je text, ktorý sa má vyhľadávať v danom jazyku.

Program sa ukončuje príkazom `exit`.

Príklad:

`sk: covid test` vráti nasledovný výsledok:

1. Rýchly antigénový test COVID-19 (sk) = Rychlý antigenní test na covid-19 (cs) = Covid19-antigén gyorsteszt (hu)
2. Rýchly antigénový test (sk) = Rychlý antigenní test (cs) = Antigén gyorsteszt (hu)
3. Turingov test (sk) = Turingův test (cs) = Turing-teszt (hu)
4. Úmrtia na COVID-19 (sk) = Zemřelí na covid-19 (cs) = Covid19-ben elhunyt személyek (hu)
5. Kolmogorovov-Smirnovov test (sk) = Kolmogorovův-Smirnovův test (cs) = Kolmogorov-Szmirnov-próba (hu)
6. Vakcíny proti chorobe COVID-19 (sk) = Vakcíny proti covidu-19 (cs) = Covid19-védőoltások (hu)
7. Pandémia ochorenia COVID-19 (sk) = Pandemie covidu-19 (cs) = Covid19-koronavírus-járvány (hu)
8. Test (sk) = Testování (cs) = Test (egyértelműsítő lap) (hu)
9. Dáta pandémie ochorenia COVID-19 (sk) = Data pandémie covidu-19 (cs) = Covid19-pandémia adatai (hu)
10. COVID-19 (sk) = Covid-19 (cs) = Covid19 (hu)
11. COVID-19 (sk) = Covid-19 (cs) = Covid19 (hu)
12. Exploration Flight Test-1 (sk) = Exploration Flight Test 1 (cs) = Exploration Flight Test 1 (hu)
13. Vakcína proti chorobe COVID-19 (sk) = Vakcína proti covidu-19 (cs) = Covid19-vakcina (hu)
14. Pandémia ochorenia COVID-19 (sk) = Pandemie covidu-19 (cs) = Covid19-pandémia (hu)

Vidíme, že na prvom mieste je výsledok, ktorý v slovenčine obsahuje slová *covid* aj *test*, keďže je najrelevantnejší. Ďalšie výsledky obsahujú iba jedno zo slov.

Referencie

[1] Pirkola, A., Hedlund, T., Keskustalo, H. and Järvelin, K., 2001. Dictionary-based cross-language information retrieval: Problems, methods, and research findings. *Information retrieval*, 4(3), pp.209-230. DOI: [10.1023/A:1011994105352](https://doi.org/10.1023/A:1011994105352).

[2] Galuščáková, P., Oard, D.W. and Nair, S., 2021. Cross-language Information Retrieval. arXiv preprint arXiv:2111.05988. DOI: [10.48550/arXiv.2111.05988](https://doi.org/10.48550/arXiv.2111.05988)