WikiTranslator

Viktor Modroczký

Vyhľadávanie informácií November 2022



SLOVENSKÁ TECHNICKÁ
UNIVERZITA V BRATISLAVE
FAKULTA INFORMATIKY
A INFORMAČNÝCH TECHNOLÓGIÍ

WikiTranslator


- Slovník spájajúci jazyky s možnosťou vyhľadávania
- Paralelné texty SK-CS-HU
- Cross-language Information Retrieval
- Java 17 + Maven
- Apache Spark distribuované spracovanie pomocou Datasetov
- Apache Lucene indexovanie a vyhľadávanie

Postup

- 1. Stiahnutie Wikipedia XML dumpov
- 2. Využitie nástroja WikiExtractor v Dockeri => JSON články
- 3. Vyhľadanie SK-CS a SK-HU párov ID článkov z SQL DB
- 4. Vytvorenie prieniku SK-CS-HU ID pomocou Apache Spark
- 5. Vyhľadanie článkov v JSON súboroch podľa ID v SK-CS-HU prieniku pomocou Apache Spark
- 6. Uloženie z nich vytvorené dokumenty (id, title, text) pomocou Apache Spark
- 7. Indexovanie pomocou Apache Lucene
- 8. Vytvorenie mapovania pre všetky jazyky:

```
{ "lang_id": [ "translation_1_id", "translation_2_id" ], ... }
```

9. Vyhľadávanie



Používateľské rozhranie

- 1. exit
- 2. find article ID pairs
- 3. create sk-cs-hu ID conjunction with Spark
- 4. create docs with Spark
- 5. create Lucene index
- 6. create ID mapping
- 7. use translation search (type 'exit' for quitting search mode)

Apache Spark

```
spark-class org.apache.spark.deploy.master.Master --host localhost
spark-class org.apache.spark.deploy.worker.Worker
spark://localhost:7077 --cores 4 --memory 1G
spark-class org.apache.spark.deploy.worker.Worker
spark://localhost:7077 --cores 4 --memory 1G
```

• GUI na localhost:8080



Spark Master at spark://localhost:7077

URL: spark://localhost:7077

Alive Workers: 2

Cores in use: 8 Total, 8 Used

Memory in use: 2.0 GiB Total, 2.0 GiB Used

Resources in use:

Applications: 1 Running, 0 Completed **Drivers:** 0 Running, 0 Completed

Status: ALIVE

→ Workers (2)

Worker Id	Address	State	Cores	Memory	Resources
worker-20221117150325-192.168.1.109-56953	192.168.1.109:56953	ALIVE	4 (4 Used)	1024.0 MiB (1024.0 MiB Used)	
worker-20221117150338-192.168.1.109-56969	192.168.1.109:56969	ALIVE	4 (4 Used)	1024.0 MiB (1024.0 MiB Used)	

▼ Running Applications (1)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
app-20221117151557-0000 (kill)	WikiTranslator	8	1024.0 MiB		2022/11/17 15:15:57	Viktor	RUNNING	2 s

▼ Completed Applications (0)



Sport 3.3.1 Application: WikiTranslator

ID: app-20221117151557-0000

Name: WikiTranslator

User: Viktor

Cores: Unlimited (8 granted)

Executor Limit: Unlimited (2 granted)

Executor Memory: 1024.0 MiB

Executor Resources:

Submit Date: 2022/11/17 15:15:57

State: RUNNING **Application Detail UI**

▼ Executor Summary (2)

ExecutorID	Worker	Cores	Memory	Resources	State	Logs
1	worker-20221117150325-192.168.1.109-56953	4	1024		RUNNING	stdout stderr
0	worker-20221117150338-192.168.1.109-56969	4	1024		RUNNING	stdout stderr

sk:T&t:covid test

ID Language Title	905 SK Turingov test				
	4218 CS Turingův test				
667655 SK Rýchly antigénový test COVID-19	182823 HU Turing-teszt				
1688511 CS Rychlý antigenní test na covid-19					
1773397 HU Covid19-antigén gyorsteszt	444545 SK Kolmogorovov-Smirnovov test				
	324710 CS Kolmogorovův?Smirnovův test				
667137 SK Rýchly antigénový test 1688600 CS Rychlý antigenní test	979361 HU Kolmogorov?Szmirnov-próba				
1774498 HU Antigén gyorsteszt	339758 SK Klasická teória testov				
645499 SK COVID-19	913998 CS Klasická testová teorie				
1564791 CS Covid-19	493883 HU Klasszikus tesztelmélet				
1683177 HU Covid19					
	652542 SK Vakcína proti chorobe COVID-19				
102017 SK Test	1651518 CS Vakcína proti covidu-19				
242872 CS Testování	1689580 HU Covid19-vakcina				
11604 HU Test (egyértelműsítő lap)					
	526502 SK Crash Test Dummies				
646838 SK Pandémia ochorenia COVID-19	694195 CS Crash Test Dummies				
1559185 CS Pandemie covidu-19	1830033 HU Crash Test Dummies				
1679312 HU Covid19-pandémia					